


Optimización: Algoritmos de Descenso

Dr. Jaime Osorio Ubaldo

Algoritmos de Descenso

- Estos algoritmos son iterativos, es decir, se inicia especificando un punto de partida y genera una serie de puntos, calculándose cada punto en función de los puntos que le preceden.



Algoritmos de Descenso

- Estos algoritmos son iterativos, es decir, se inicia especificando un punto de partida y genera una serie de puntos, calculándose cada punto en función de los puntos que le preceden.
- A medida que se genera un punto nuevo, el valor correspondiente de cierta función decrece.


Algoritmos de Descenso

- Estos algoritmos son iterativos, es decir, se inicia especificando un punto de partida y genera una serie de puntos, calculándose cada punto en función de los puntos que le preceden.
- A medida que se genera un punto nuevo, el valor correspondiente de cierta función decrece.
- Idealmente la sucesión de puntos generados por el algoritmo converge en un número finito o infinito de pasos a la solución del problema original.

Criterios de Parada

Sea $\epsilon > 0$ y $N \in \mathbb{Z}^+$, para detener el algoritmo de descenso podemos usar los siguientes criterios :

- 1) $\|x_{k+N} - x_k\| < \epsilon$
- 2) $\frac{\|x_{k+N} - x_k\|}{\|x_k\|} < \epsilon.$
- 3) $A(x_k) - A(x_{k+N}) < \epsilon$
- 4) $\frac{A(x_k) - A(x_{k+N})}{|A(x_k)|} < \epsilon$
- 5) $A(x_k) - A(x^*)$, siendo $x^* \in T$.



First-Order Method

- Es un algoritmo de descenso.
- Utilizan como herramienta principal la primera derivada para optimizar.

Gradiente Descent

https://www.youtube.com/watch?v=A6FiCDoz8_4&t=29s.

Gradiente Descent

https://www.youtube.com/watch?v=A6FiCDoz8_4&t=29s.

- Es uno de los más antiguos y conocidos de minimización de una función de varias variables, también llamado método de descenso de mayor pendiente.

Gradiente Descent

https://www.youtube.com/watch?v=A6FiCDoz8_4&t=29s.

- Es uno de los más antiguos y conocidos de minimización de una función de varias variables, también llamado método de descenso de mayor pendiente.
- Es uno de los más sencillos y utilizados en un problema nuevo.

Gradiente Descend

https://www.youtube.com/watch?v=A6FiCDoz8_4&t=29s.

- Es uno de los más antiguos y conocidos de minimización de una función de varias variables, también llamado método de descenso de mayor pendiente.
- Es uno de los más sencillos y utilizados en un problema nuevo.
- Se han conseguido algoritmos más avanzados modificando este algoritmo como: **Conjugate Gradient, Momentum, Nesterow Momentum, Adagrad, RMSProp, Adam, Hypergradient Descent.**

Gradiente Descent

- Sea f una función con derivadas parciales continuas.


Gradiente Descendente

- Sea f una función con derivadas parciales continuas.
- Este método está definido por el algoritmo iterativo

$$x_{i+1} = x_i - \alpha_i \nabla f(x_i)$$

donde α_i es denominado radio de aprendizaje

$$\alpha_i > 0$$



Gradiente Descent

- Sea f una función con derivadas parciales continuas.
- Este método está definido por el algoritmo iterativo

$$x_{i+1} = x_i - \alpha_i \nabla f(x_i)$$

donde α_i es denominado radio de aprendizaje

- En este método se debe escoger un punto inicial.


Gradiente Descendente

- Sea f una función con derivadas parciales continuas.
- Este método está definido por el algoritmo iterativo

$$x_{i+1} = x_i - \alpha_i \nabla f(x_i)$$

donde α_i es denominado radio de aprendizaje

- En este método se debe escoger un punto inicial.
- Este algoritmo termina cuando dos puntos sucesivos de ensayo x_i y x_{i+1} son aproximadamente iguales. Equivalentemente la terminación puede ocurrir en x_i solo si $\nabla f(x_i) = 0$.



- Elegir α_i es el mínimo de la función $g(\alpha) = f(x_i - \alpha \nabla f(x_i))$ para mejorar velocidad de movimiento.


Tamaño de paso o radio de aprendizaje

- Elegir α_i es el mínimo de la función $g(\alpha) = f(x_i - \alpha \nabla f(x_i))$ para mejorar velocidad de movimiento.
- En lugar de $\nabla f(x_i)$ podemos usar $\frac{\nabla f(x_i)}{\|f(x_i)\|}$ permite que el espacio de búsqueda sea más regular (ni muy estrecho ni muy largo).

Tamaño de paso o radio de aprendizaje

- Elegir α_i es el mínimo de la función $g(\alpha) = f(x_i - \alpha \nabla f(x_i))$ para mejorar velocidad de movimiento.
- En lugar de $\nabla f(x_i)$ podemos usar $\frac{\nabla f(x_i)}{\|\nabla f(x_i)\|}$ permite que el espacio de búsqueda sea más regular (ni muy estrecho ni muy largo).
- $\nabla f(x_{k+1})$ y $\nabla f(x_k)$ son vectores son ortogonales, es decir

$$\nabla f(x_{k+1}) \cdot \nabla f(x_k) = 0$$




Ejemplo

Sea la función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por

$$\nabla f(x) = 2x, \quad f(x) = x^2$$

Determine $\text{Min} f(x)$, iniciando en $x_1 = -2$.



$$\begin{aligned} x_2 &= x_1 - \alpha_1 \nabla f(x_1) \\ &= -2 - \alpha_1 (2(-2)) = 4\alpha_1 - 2 \end{aligned}$$

El radio de aprendizaje

$$\begin{aligned} \alpha_1 &= \min f(x_1 - \alpha \nabla f(x_1)) \\ &= \min f(-2 + 4\alpha) \end{aligned}$$

Ejemplo

$$= \min (-2 + 4\alpha)^2$$

$$\textcircled{1} f'(\alpha) = 2(-2 + 4\alpha)(4) = 0$$


$$\alpha = 1/2$$

$$\textcircled{2} f''(\alpha) = 8(4) = 32 > 0$$

$\rightarrow \alpha = 1/2$ es mínimo.

$$\rightarrow \alpha_1 = 1/2$$

$$x_2 = 4\left(\frac{1}{2}\right) - 2 = 0$$



Ejemplo

Ejemplo

Ejemplo

Ejemplo

Sea la función $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por

$$f(x, y) = xy^2 \rightarrow \nabla f(x, y) = (f_x, f_y) = (y^2, 2xy)$$

Calcule el mínimo de f iniciando en $x_1 = (1, 2)$.

$$x_2 = x_1 - \alpha_1 \nabla f(x_1)$$

$$\begin{aligned} \text{donde } \alpha_1 &= \min_{\alpha} f(x_1 - \alpha \nabla f(x_1)) \\ &= \min_{\alpha} f((1, 2) - \alpha(4, 4)) \\ &= \min_{\alpha} f(1 - 4\alpha, 2 - 4\alpha) \\ &= \min_{\alpha} (1 - 4\alpha)(2 - 4\alpha)^2 \end{aligned}$$

Ejemplo

$$\begin{aligned} \textcircled{1} \quad & -4(2-4\alpha)^2 + 2(1-4\alpha)(2-4\alpha)(-4) \\ & (2-4\alpha) \left[\underbrace{-4(2-4\alpha) - 8(1-4\alpha)}_{(40\alpha-16)} \right] = 0 \\ & \alpha = \frac{1}{2} \qquad 40\alpha = 16 \\ & \qquad \qquad \qquad \alpha = \frac{2}{5} \end{aligned}$$

$$\textcircled{2} \quad -4(40\alpha-16) + (2-4\alpha)40$$

$$\text{Si } \alpha = \frac{1}{2}: \quad -16 + 0 = -16 < 0$$

$\nwarrow$ es un máximo

$$\text{Si } \alpha = \frac{2}{5}: \quad \frac{2}{5} \times 40 = 16 > 0$$

$\nwarrow$ es un mínimo

$$\begin{aligned} X_2 &= X_1 - \frac{2}{5} \nabla f(X_1) \\ &= (1, 2) - \frac{2}{5} (4, 4) = \left(-\frac{3}{5}, \frac{2}{5}\right) \end{aligned}$$

Ejemplo

Ejemplo

Ejemplo

Ejemplo

Algoritmo de Descenso: Método de Newton

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase C^2 . Se puede construir una función cuadrática g que aproxime a f en x_k hasta la segunda derivada, es decir,

$$g(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2.$$

Derivando: $f'(x_k) + \frac{1}{2}f''(x_k) \cdot 2(x - x_k) = 0$

$$f''(x_k)(x - x_k) = -f'(x_k)$$
$$x - x_k = -\frac{f'(x_k)}{f''(x_k)}$$
$$\therefore x = x_k - \frac{f'(x_k)}{f''(x_k)}$$

Algoritmo de Descenso: Método de Newton

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase C^2 . Se puede construir una función cuadrática g que aproxime a f en x_k hasta la segunda derivada, es decir,

$$g(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2.$$

Se puede estimar x_{k+1} del punto mínimo de f hallando el punto en el que se anula la derivada de g . Luego

$$0 = g'(x_{k+1}) = f'(x_k) + f''(x_k)(x_{k+1} - x_k)$$

Algoritmo de Descenso: Método de Newton

Sea $f : \mathbb{R} \rightarrow \mathbb{R}$ una función de clase C^2 . Se puede construir una función cuadrática g que aproxime a f en x_k hasta la segunda derivada, es decir,


$$g(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2.$$

Se puede estimar x_{k+1} del punto mínimo de f hallando el punto en el que se anula la derivada de g . Luego

$$0 = g'(x_{k+1}) = f'(x_k) + f''(x_k)(x_{k+1} - x_k)$$

Por lo tanto,


$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}.$$



Graficamente


Problemas de convergencia

- Oscillation (repita valores anteriores)



Problemas de convergencia


- Oscillation (repita valores anteriores)
- Overshoot (se aleje del mínimo)



Problemas de convergencia

- Oscillation (repita valores anteriores)
- Overshoot (se aleje del mínimo)
- $f''(x) \leq 0$ (en lugar de disminuir, aumente).

$$x_{k+1} = x_k - \frac{f'(x_k)}{\underbrace{f''(x_k)}_{\ominus}}$$



Ejemplo

Minimizar la función f definida por $f(x) = x^4 - 2x^2$, $f'(x) = 4x^3 - 4x$
 $f''(x) = 12x^2 - 4$

- Iniciando en $x_1 = 1.1$
- Iniciando en $x_1 = 0.5$

$$\begin{aligned}x_2 &= x_1 - \frac{f'(x_1)}{f''(x_1)} \\&= 1.1 - \frac{4(1.1)^3 - 4(1.1)}{12(1.1)^2 - 4} \\&= \rightarrow\end{aligned}$$

Ejemplo

Ejemplo

Método de Newton

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ Para minimizar una función f este método se basa en aproximarlos mediante la expansión de Taylor.

$$g(x) = f(x_k) + \nabla f^T(x_k)(x - x_k) + \frac{1}{2}(x - x_k)^T H(x_k)(x - x_k)$$

Método de Newton

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ Para minimizar una función f este método se basa en aproximarla mediante la expansión de Taylor.

$$g(x) = f(x_k) + \nabla f^T(x_k)(x - x_k) + \frac{1}{2}(x - x_k)^T H(x_k)(x - x_k)$$

supongamos que $H(x_k)$ es definida positiva entonces se alcanza un mínimo local no restringido y que

$$\nabla g(x) = \nabla f(x_k) + H(x_k)(x - x_k) = 0$$

siendo la matriz hessiana invertible.

Método de Newton

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$ Para minimizar una función f este método se basa en aproximarla mediante la expansión de Taylor.

$$g(x) = f(x_k) + \nabla f^T(x_k)(x - x_k) + \frac{1}{2}(x - x_k)^T H(x_k)(x - x_k)$$

Handwritten notes: A blue arrow points from the $(x - x_k)$ term in the quadratic term to the $(x - x_k)$ term in the linear term. Below the quadratic term, there is a blue expression $\frac{1}{2}(x - x_k)$.

supongamos que $H(x_k)$ es definida positiva entonces se alcanza un mínimo local no restringido y que

$$\nabla g(x) = \nabla f(x_k) + H(x_k)(x - x_k) = 0$$

Handwritten notes: Below the equation, there is a red expression $H(x_k)^{-1} H(x_k)(x - x_k) = -H(x_k)^{-1} \nabla f(x_k)$.

siendo la matriz hessiana invertible. El valor de minimización de x es dado por

$$x_{k+1} = x_k - H^{-1}(x_k) \nabla f(x_k).$$

Ejemplo

Calcule

$$\max f(x, y) = -x^2 + x - y^2 - 10$$

Inicie en $(1, 1)$.

$$\nabla f(x, y) = (f_x, f_y) = (-2x + 1, -2y)$$

$$H(x, y) = \begin{bmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{bmatrix} = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}$$

$$\left[\begin{array}{cc|cc} -2 & 0 & 1 & 0 \\ 0 & -2 & 0 & 1 \end{array} \right] \rightarrow \left[\begin{array}{cc|cc} 1 & 0 & -1/2 & 0 \\ 0 & 1 & 0 & -1/2 \end{array} \right]$$

$$H^{-1}(x, y) = \begin{bmatrix} -1/2 & 0 \\ 0 & -1/2 \end{bmatrix}$$

Ejemplo

$$\begin{aligned}x_2 &= x_1 - H^{-1}(x_1) \cdot \nabla f(x_1) \\&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} -1/2 & 0 \\ 0 & -1/2 \end{bmatrix} \begin{bmatrix} -1 \\ -2 \end{bmatrix} \\&= \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \begin{bmatrix} 1/2 \\ 1 \end{bmatrix} \\&= \begin{bmatrix} 1/2 \\ 0 \end{bmatrix}\end{aligned}$$

Ejemplo

Ejemplo

Ejemplo

Tarea

Sea la función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por

$$f(x, y) = x^2 + y^2 + xy - 3x$$

- 1) Calcule el mínimo local de la función f usando los puntos críticos y el criterio de la segunda derivada.
- 2) Ahora con el método del gradiente y el método de Newton aplique 1 iteración en cada uno. Inicie con (2,2).
- 3) Codifique los métodos anteriores y compare los resultados para 5, 100 y 1000 iteraciones.

	5 iter	100 iter	1000 iter.
Gradiente	(,)		
Newton	(,)		

Enviar 3 archivos (pdf, cod1, cod2)

Ejercicio

Tomando como punto inicial el $(2, 3)$ realice dos iteraciones en el método del gradiente para calcular el mínimo de la función $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por

$$f(x, y) = x^3 + y^3 - 3xy$$

y compare este resultado con el mínimo.

Ejercicio

$$\max f(x) = 3x^2 - x^3$$

Inicie con $x_0 = 1.1$

Ejercicio

Minimizar

$$f(x, y) = (x - 1)^3 + (y - 2)^2$$

Inicie en $(0, 0)$ y realice dos iteraciones.

Ejercicio

$$\max f(x, y) = x(x - 3)^2 - 5y^2$$

Inicie en $(0, 0)$.

Ejercicio

Calcule

$$\max f(x_1, x_2) = -\sin(xy) + \cos(x - y)$$

Iniciando en $(\frac{1}{2}, \frac{1}{2})$.

Ejercicio

Calcule

$$\min f(x, y, z) = \frac{40}{xyz} + 40yz + 10xy + 20xz$$

donde el punto inicial es $x_0 = (6, 4, 5)$.

Ejercicio

Sea la función $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ definida por

$$g(x_1, x_2) = 4x_1 + 6x_2 - 2x_1^2 - 2x_1x_2 - 2x_2^2.$$

Calcule el máximo de g iniciando en $(1, 1)$.